Marco Teórico y Metodológico para la Detección de Fraude Transaccional en Entidades Financieras: Un Enfoque CRISP-DM, Jurídico y Ético

La rápida digitalización del ecosistema financiero global y la adopción masiva de canales de pago electrónicos han transformado radicalmente la naturaleza del comercio, generando simultáneamente una evolución sin precedentes en las tipologías de cibercrimen y fraude económico.[1] Para las entidades bancarias contemporáneas, la capacidad de identificar, interceptar y neutralizar operaciones ilícitas en tiempo real ha dejado de ser un mero valor agregado de carácter tecnológico para convertirse en una obligación legal imperativa, una necesidad operativa crítica y un pilar de supervivencia estratégica.[3] El diseño e implementación de sistemas de Inteligencia Artificial (IA) y Machine Learning (ML) orientados a la detección de fraude exigen un marco de desarrollo excepcionalmente riguroso, el cual debe ser estructurado a través de estándares industriales probados como la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining).[5]

El presente informe desarrolla un análisis exhaustivo y pormenorizado de las cuatro fases fundamentales para la conceptualización, diseño, justificación y despliegue de un modelo avanzado de clasificación de fraude transaccional. El análisis articula de manera integral la comprensión del negocio desde sus dimensiones jurídicas y operacionales en el contexto estricto de la República de Colombia, la preparación de datos y el modelado predictivo mediante técnicas científicas para el tratamiento de clases desbalanceadas y ensambles algorítmicos, y la evaluación profunda del impacto ético derivado de la automatización de decisiones financieras críticas que afectan los derechos de los consumidores.

Fase 1: Marco Legal y Debido Proceso Institucional

El entendimiento del negocio en el marco de un proyecto de ciencia de datos aplicado a la detección de fraude requiere asimilar primeramente la intrincada red de responsabilidades legales que rigen a las instituciones financieras bajo la jurisdicción colombiana. El despliegue de modelos algorítmicos para bloquear transacciones opera de forma permanente en la delgada línea entre la protección diligente del patrimonio institucional, la prevención de delitos de alto impacto socioeconómico y la potencial vulneración de los derechos constitucionales fundamentales de los consumidores financieros.

Tensión Jurídica entre la Prevención del Delito y la Posición de Garante

El Código Penal Colombiano (Ley 599 de 2000) impone a las entidades financieras, de manera

implícita y explícita a través de legislaciones complementarias y directrices de la Superintendencia Financiera de Colombia (SFC), el deber irrenunciable de establecer controles estrictos para evitar que sus infraestructuras tecnológicas y plataformas de pago sean utilizadas como instrumentos facilitadores para la materialización de conductas punibles.[6] Específicamente, el marco normativo exige a las organizaciones mitigar proactivamente los riesgos asociados a la Estafa (Tipificada en el Art. 246), la Captación masiva y habitual de dineros (Art. 316), el Lavado de activos (Art. 323) y el Enriquecimiento ilícito de particulares (Art. 327).[8]

La jurisprudencia y la normatividad, incluyendo los lineamientos del Sistema de Administración del Riesgo de Lavado de Activos y de la Financiación del Terrorismo (SARLAFT), determinan que la omisión de estos controles antifraude no es un simple fallo técnico, sino una infracción que, bajo la figura dogmática de la posición de garante, puede derivar en responsabilidades penales, administrativas e institucionales severas frente al Estado colombiano y sus entidades de control, como la Unidad de Información y Análisis Financiero (UIAF).[6] La automatización mediante IA se erige, por tanto, como un escudo legal y operativo indispensable frente al volumen de transacciones que desborda la capacidad de auditoría humana.

Responsabilidad Civil Extracontractual y el Deber de Seguridad Institucional

Simultáneamente a la responsabilidad penal, la entidad financiera asume una responsabilidad civil y profesional inherente a su modelo de negocio. La Corte Suprema de Justicia de Colombia (CSJ), a través de una vasta y consolidada jurisprudencia (ejemplificada en sentencias hito como la SC16496-2016 y la SC976-2004), ha determinado inequívocamente que el contrato de cuenta corriente bancaria o de depósito de ahorros conlleva un deber intrínseco, irrenunciable y profesional de seguridad y protección.[13]

Frente al retiro fraudulento, la clonación de tarjetas o la suplantación de identidad en canales digitales, se activa inmediatamente la aplicación del Artículo 2341 del Código Civil Colombiano, el cual regula la Responsabilidad civil extracontractual, sumado a la responsabilidad contractual derivada del acuerdo de voluntades.[14] La Sala de Casación Civil de la CSJ y la Delegatura para Funciones Jurisdiccionales de la SFC han reiterado consistentemente que las instituciones financieras ejercen una actividad profesional, especializada y habitual de la cual derivan un provecho económico sustancial. En consecuencia, a esta actividad le es inherente una multiplicidad de peligros operacionales y tecnológicos que pueden afectar gravemente los intereses patrimoniales de los cuentahabientes.[16]

Este precepto legal establece que si un modelo de Inteligencia Artificial es estadísticamente ineficiente, subentrenado o mal calibrado, y permite la consumación del fraude (es decir, incurre en un "falso negativo" desde la perspectiva de la matriz de confusión), el banco está en la obligación jurídica de asumir el impacto económico y restituir íntegramente los fondos al cliente defraudado.[17] Las excepciones formuladas por las entidades bancarias para evadir esta responsabilidad están llamadas al fracaso procesal, a menos que logren demostrar de manera

fehaciente e inequívoca en un estrado judicial la culpa exclusiva, inexcusable y grave del titular del producto financiero (por ejemplo, la entrega voluntaria, consciente y comprobable de sus credenciales de acceso, contraseñas y tokens físicos a terceros delincuentes).[13]

El Derecho Fundamental al Hábeas Data y la Problemática del Falso Positivo

Como respuesta a la severidad de la responsabilidad civil y penal descrita, las instituciones financieras tienden a configurar sus clasificadores de IA con políticas excesivamente restrictivas, orientadas obsesivamente a minimizar los falsos negativos. Sin embargo, esta calibración irremediablemente eleva la tasa de falsos positivos, es decir, transacciones completamente legítimas que son catalogadas erróneamente por el algoritmo como intentos de fraude. Este bloqueo preventivo y automatizado entra en colisión directa, frontal y constitucional con el Artículo 15 de la Constitución Política de Colombia, el cual consagra y garantiza el derecho fundamental al Hábeas Data, a la intimidad personal y familiar, y al buen nombre.[19]

Bloquear indiscriminadamente los fondos de un usuario legítimo restringe severamente su derecho al mínimo vital, su acceso a la alimentación, a la salud y su capacidad de participación ordinaria en la vida económica. La Corte Constitucional de Colombia ha calificado esta afectación como de altísima gravedad, especialmente si el bloqueo preventivo se sostiene prolongadamente en el tiempo sin justificación clara o sin vías de solución, llegando a afectar cuentas destinadas al pago de nóminas o mesadas pensionales.[22] Adicionalmente, el procesamiento y eventual reporte erróneo de estas actividades ciudadanas como "sospechosas" o "fraudulentas" en las bases de datos de centrales de riesgo financiero vulnera flagrantemente los principios rectores de veracidad, necesidad, utilidad y circulación restringida de los datos personales, los cuales están celosamente protegidos por la Ley 1266 de 2008 (conocida como la Ley Estatutaria de Hábeas Data Financiero).[20] La Corte ha dictaminado mediante jurisprudencia reiterada (como la Sentencia SU-082 de 1995 y la T-113 de 2025) que la información financiera debe administrarse bajo estrictos criterios de razonabilidad, impidiendo que los algoritmos perpetúen reportes negativos infundados que anulen la personalidad jurídica o la reputación crediticia del ciudadano.[20]

Configuración del Debido Proceso Técnico, Legal y Operativo

La interrogante central en esta primera fase de la metodología CRISP-DM radica en establecer cuál debe ser el "debido proceso" holístico que la organización debe diseñar para mitigar la afectación al usuario cuando el modelo de ML clasifica erróneamente una transacción. La jurisprudencia constitucional (e.g., Sentencias T-716 de 2017 y T-479 de 2023) y la robusta doctrina administrativa de la SFC establecen de forma perentoria que ninguna restricción tecnológica, por muy avanzada que sea la IA subyacente, puede convertirse en una barrera absoluta, perpetua, opaca o irrazonable para el goce pleno de los derechos financieros.[23]

La Ley 1328 de 2009, en su Artículo 3, consagra el principio rector de "debida diligencia", obligando a todas las entidades vigiladas a prestar un servicio con los más altos estándares de

seguridad y calidad, priorizando siempre la atención respetuosa y eficiente al consumidor financiero.[17] La Superintendencia Financiera, mediante las disposiciones de su Circular Básica Jurídica (Circular Externa 29 de 2014 y actualizaciones normativas de 2024), instruye claramente que es legalmente lícito, válido y operacionalmente necesario contar con procedimientos de bloqueo preventivo inmediato de canales o instrumentos cuando los sistemas de monitoreo detecten riesgos inminentes o patrones anómalos (incluyendo intentos fallidos repetitivos de acceso).[17] Sin embargo, este bloqueo tecnológico de carácter cautelar carece de absoluta legalidad y legitimidad si no está intrínsecamente acompañado de un procedimiento expedito, transparente y accesible de reactivación y verificación.[17]

El debido proceso integral que la organización financiera debe establecer comprende tres dimensiones estructurales que deben operar en sincronía:

1. **Dimensión Técnica:** El modelo de clasificación (sea Regresión Logística, Random Forest o CatBoost) debe estar rigurosamente calibrado y contar con un umbral de decisión (threshold) dinámico, matemáticamente justificado, que evalúe el nivel real e individualizado de riesgo, evitando políticas de bloqueo generalizadas ("one-size-fits-all").[31] Adicionalmente, la Corte Constitucional ha prohibido de forma taxativa que los antecedentes históricos del cliente (como antiguas fricciones penales ya purgadas) operen como el único vector determinístico para excluir a un usuario del sistema, previniendo así el bloqueo sistemático fundamentado en la estigmatización algorítmica y la discriminación perpetua.[11]
2. **Dimensión Operacional:** En estricto cumplimiento de las instrucciones y circulares de la SFC, la entidad bancaria debe proveer canales de contingencia inmediatos y de fácil acceso para el consumidor.[17] Un bloqueo generado automáticamente por la red neuronal o el ensamble de árboles de decisión debe gatillar una notificación al cliente en tiempo real (vía SMS, correo electrónico o aplicación móvil). Esta notificación debe ofrecer una vía de validación multifactorial secundaria (como biometría facial avanzada, validación de identidad basada en conocimiento o el uso de tokens criptográficos dinámicos) que le permita al usuario legítimo comprobar su identidad y sobreescribir la predicción errónea de la máquina en cuestión de minutos.[18] La carga burocrática y probatoria de la rectificación del falso positivo no debe recaer de manera desproporcionada, extenuante o asimétrica sobre el ciudadano.[17]
3. **Dimensión Legal y Jurisdiccional:** Si el bloqueo preventivo persiste debido a una sospecha sólidamente fundada y corroborada por análisis humanos posteriores (lo que desencadena reportes obligatorios de operaciones sospechosas a la UIAF), la entidad debe observar escrupulosamente los límites constitucionales de su jurisdicción privada. Las plataformas tecnológicas de los bancos no son entes judiciales y no pueden ejercer funciones de juzgamiento punitivo ni expropiatorio.[11] En escenarios donde ocurren bloqueos prolongados que afectan derechos inalienables como el acceso a cuentas de nómina, ahorros vitales o mesadas de seguridad social, el ordenamiento jurídico colombiano activa la procedencia excepcional y urgente de la Acción de Tutela. En este escenario, el juez de la república ponderará, bajo el principio de proporcionalidad, el

derecho individual al mínimo vital y la honra frente a las políticas corporativas de mitigación de riesgo.[22]

Fase 2: Contexto Operacional y Estratégico

La estrategia para combatir el fraude mediante arquitecturas de Machine Learning no opera en un vacío conceptual. Por el contrario, está profundamente condicionada por el entorno macroeconómico en constante disrupción, los cambiantes hábitos de consumo de los clientes bancarios y la evolución vertiginosa de la infraestructura tecnológica del sistema financiero global y regional. En esta etapa de entendimiento del ecosistema (Business Understanding), es crucial mapear los vectores de presión que moldean la implementación de la IA.

El Volumen Masivo de Datos y la Metamorfosis del Ecosistema de Pagos

La incesante digitalización del comercio minorista y la aparición de normativas disruptivas como las Finanzas Abiertas (Open Finance) impulsadas por entidades como la SFC en Colombia, han multiplicado exponencialmente el volumen, la velocidad y la variedad de las transacciones electrónicas.[37] Reportes especializados de inteligencia de mercados y tendencias del consumidor global, tales como los emitidos por Euromonitor International para el periodo 2024-2025, advierten que la transformación sistémica hacia economías desmaterializadas y sin efectivo (cashless societies) en América Latina es, indiscutiblemente, la macrotendencia dominante en el sector financiero.[39]

Este paradigma está siendo acelerado vigorosamente por la penetración de plataformas de pago de liquidación bruta en tiempo real, cuyo máximo exponente regional es el sistema Pix en Brasil (y sus inminentes evoluciones como Pix Automático), acompañadas de sistemas equivalentes y ecosistemas Fintech emergentes en naciones como Colombia, Chile y México, donde la inclusión financiera de poblaciones históricamente no bancarizadas está experimentando un auge sin precedentes.[41] Particularmente, el segmento de comercio móvil (m-commerce) y las billeteras digitales han exhibido tasas de crecimiento proyectadas astronómicas, superando expansiones del 250% en periodos de cinco años.[4]

Frente a este escenario, el flujo masivo e ininterrumpido de datos transaccionales —que amalgama variables estructuradas tradicionales con metadatos no estructurados de navegación y geolocalización— obliga a las infraestructuras de las entidades financieras a procesar, analizar y clasificar millones de registros por segundo con latencias inferiores a los cientos de milisegundos.[37] La abrumadora escala computacional de este ecosistema vuelve completamente obsoletos, ineficientes y peligrosos a los sistemas legados basados en reglas heurísticas estáticas o en la auditoría manual humana retrospectiva.[1]

De manera simultánea a la conveniencia tecnológica, la diversificación de canales digitales fomenta la proliferación de fraudes altamente complejos y estructurados. Las tipologías criminales han mutado desde la simple falsificación física del plástico hacia delitos cibernéticos

sofisticados, tales como el robo de identidad y apropiación de cuentas (Account Takeover), las estafas autorizadas mediante ingeniería social (donde la víctima es manipulada psicológicamente para realizar y autorizar la transferencia ilícita), y el fraude masivo en transacciones sin tarjeta presente (Card-Not-Present o CNP) en plataformas de comercio electrónico transfronterizo.[4] Informes sectoriales y análisis científicos recientes estiman con alarma que las pérdidas financieras globales derivadas exclusivamente del fraude en tarjetas de crédito han superado holgadamente la barrera de los 33.5 mil millones de dólares, demostrando una tendencia sostenida a escalar progresivamente año tras año.[47]

El Equilibrio Costo-Beneficio: El Costo de la Fricción vs. La Pérdida Financiera Materializada

El colosal impacto operativo de este ecosistema de alto rendimiento y riesgo permanente obliga a la organización bancaria a plantear una estrategia de adopción de Inteligencia Artificial orientada no solo a la sofisticación algorítmica, sino al equilibrio estadístico y económico fundamentado. La pregunta crítica a nivel de estrategia de negocio en la metodología CRISP-DM es: ¿Cómo se determina el punto matemático óptimo entre detener una transacción sospechosa (protegiendo el capital) y permitirla fluir (protegiendo la experiencia del usuario)?

Por un lado, el costo financiero, reputacional y regulatorio del fraude materializado recae con un peso demoledor directamente sobre los balances contables (P&L) de la institución bancaria. La literatura especializada en gestión de riesgos determina que cada dólar perdido ante el cibercrimen representa un impacto asimétrico. Debido a los costos agregados asociados a la restitución del saldo al cliente, los gastos forenses y legales de investigación corporativa, las penalizaciones pecuniarias impuestas por entes de supervisión como la SFC, y la incalculable pérdida de confianza y lealtad del mercado, el costo real del fraude opera como un multiplicador pernicioso de pérdidas netas en la estructura de la institución.[46]

Frente a esta amenaza, la reacción tecnológica intuitiva pero defectuosa sería maximizar al extremo la sensibilidad del modelo predictivo (la métrica estadística de *Recall* o Tasa de Verdaderos Positivos) para garantizar la intercepción del 100% de las actividades fraudulentas. Sin embargo, la implementación de este enfoque draconiano produce inexorablemente una cascada masiva e inmanejable de falsos positivos.[32]

La literatura científica sobre economía bancaria y el comportamiento del consumidor digital demuestra empíricamente que el "costo de la fricción" derivado de clasificaciones erróneas es económicamente severo y altamente destructivo para el Valor de Vida del Cliente (Customer Lifetime Value - CLV). Investigaciones detalladas en el espacio de prevención del crimen financiero advierten que cerca del 43% de las instituciones de crédito y emisores de pagos experimentan aumentos dramáticos en la tasa de falsos positivos inmediatamente después de desplegar nuevos modelos predictivos no calibrados económicamente.[45] Las consecuencias operativas y financieras de esta alta fricción transaccional son bidimensionales:

1. **Carga Operativa Asfixiante del Back-Office:** Cada alerta levantada por el modelo algorítmico exige, por protocolos de cumplimiento, una supervisión, validación y posible

investigación humana. Esta avalancha de alertas espurias consume rápidamente los valiosos y costosos recursos humanos y tecnológicos del área de prevención de fraudes y servicio al cliente, saturando la capacidad de respuesta de la organización y paralizando el flujo operativo estándar.[17]

2. **Abandono Crítico y Churn del Cliente:** Según estudios de consultoras especializadas analizados en la industria, más del 58% de las empresas minoristas y corporaciones de comercio electrónico reportan incrementos alarmantes en la tasa de abandono de clientes (Customer Churn) y deserción en el proceso de "onboarding" o pago final, fenómenos directamente vinculados a procesos transaccionales friccionados y obstaculizados por controles antifraude agresivos.[51] El cliente legítimo, cuya compra rutinaria es denegada, retenida o bloqueada repetidamente en el punto de venta digital sin justificación aparente, experimenta un deterioro severo en la percepción de calidad del servicio, pierde rápidamente la confianza en su medio de pago principal y, eventualmente, migra sus recursos hacia un competidor financiero que ofrezca una experiencia sin fricciones.[49]

Por consiguiente, la estrategia metodológica de la organización de cara al modelado predictivo no puede apuntar a la optimización de métricas técnicas aisladas y agnósticas al contexto comercial, como la "Precisión Global" (Accuracy) del algoritmo.[52] En su lugar, el proyecto debe estar subyugado a una estrategia de optimización del Indicador Clave de Rendimiento (KPI) denominado "Ganancia Neta" (Net Gain).[5] Esta aproximación se basa en un paradigma avanzado de Machine Learning conocido como Aprendizaje Sensible al Costo (Cost-Sensitive Learning), el cual postula la optimización económica del modelo partiendo de la premisa fundamental de que el costo de un falso negativo (un fraude cibernético multimillonario consumado) es estadística y operativamente asimétrico frente al costo de un falso positivo (el gasto administrativo de contacto y la incomodidad temporal del cliente).[31] El objetivo estratégico es alcanzar el equilibrio matemático exacto donde se minimice el impacto económico consolidado de las pérdidas por fraude sin asfixiar ni deteriorar la agilidad comercial, el crecimiento transaccional y la satisfacción de la base de clientes del banco.[5]

Fase 3: Justificación Científica del Preprocesamiento y Modelado

Siguiendo el flujo secuencial y sistemático de la metodología CRISP-DM, la comprensión madura del negocio y del comportamiento de los datos transita ineludiblemente hacia la fase técnica y científica de preparación de la información y modelado predictivo. El análisis computacional de transacciones financieras presenta un reto técnico inherente y fundamental que ha ocupado gran parte de la investigación moderna en ciencia de datos: el problema del desbalance extremo de las clases (Class Imbalance Problem).[55] En las bases de datos de naturaleza transaccional que reposan en las arquitecturas bancarias, las operaciones fraudulentas representan una ínfima y anómala fracción del universo de datos (frecuentemente constituyendo menos del 0.2% o 0.17% del total de eventos registrados) en contraste con la

inmensa y abrumadora mayoría de transacciones legítimas.[56]

Si los algoritmos de Inteligencia Artificial son expuestos a esta distribución natural sin recibir un preprocesamiento estadístico exhaustivo, el sesgo algorítmico inducirá a la red o al ensamble a predecir siempre la clase mayoritaria en la totalidad de los casos. Este fenómeno estadístico genera una "paradoja de la precisión" (Accuracy Paradox), logrando una precisión aparente, reconfortante pero matemáticamente engañosa del 99.8% o superior, mientras que el modelo fracasa de forma absoluta y estrepitosa en su única tarea funcional: la detección de la clase minoritaria que representa el fraude.[55]

El Impacto Científico del Manejo de Clases Desbalanceadas

Para mitigar radicalmente este riesgo sistémico de sesgo estadístico, la literatura científica exhaustiva revisada por pares (indexada en repositorios de rigor académico como IEEE Xplore, Scopus, ACM Digital Library y Web of Science) propone, evalúa y valida diversas técnicas de remuestreo aplicables a conjuntos de datos de crímenes financieros.[55] La manipulación controlada y algorítmica de la distribución de las clases en la base de datos de entrenamiento antes de la alimentación de la red neuronal o los árboles de decisión es un paso metodológico imperativo. La investigación contemporánea se centra en tres enfoques primarios de manipulación de dimensionalidad:

Técnica de Preprocesamiento y Remuestreo	**Mecanismo Científico Subyacente**	**Ventajas Empíricas Justificadas en la Literatura**	**Riesgos Inherentes y Desventajas Teóricas**
Undersampling (Submuestreo de la Clase Mayoritaria)	Reducción drástica del conjunto de datos mediante la eliminación estocástica, aleatoria o guiada heurísticamente de datos pertenecientes a la clase mayoritaria (transacciones legítimas) hasta lograr una paridad o equilibrio proporcional con la incidencia de la	Reduce sustancialmente la carga en memoria y mejora drásticamente los tiempos computacionales de procesamiento y entrenamiento de la máquina. Ayuda a que el algoritmo converja con rapidez matemática y neutraliza el sesgo de clasificación hacia	Causa una pérdida crítica, irrecuperable y masiva de información valiosa y varianza estadística. Desecha indiscriminadamente patrones transaccionales legítimos que son fundamentales para la capacidad de generalización del algoritmo en

	clase minoritaria.[57]	la clase numéricamente dominante.[58]	producción, incrementando severamente el riesgo de subajuste (underfitting) del modelo y la miopía predictiva.[58]
Oversampling (Sobremuestreo de la Clase Minoritaria)	Replicación aleatoria, probabilística o determinística de los ejemplos históricos existentes pertenecientes a la clase minoritaria (fraude) para incrementar artificialmente su presencia, peso estadístico e influencia en el espacio vectorial y la función de pérdida del modelo.[57]	Permite retener y aprovechar la totalidad de la vasta riqueza de datos de la clase mayoritaria legítima sin destruir información útil. Mejora directamente la visibilidad, impacto e importancia del evento anómalo raro en el cálculo iterativo del gradiente durante la fase de aprendizaje automático.[57]	Representa un alto y comprobado riesgo de sobreajuste (overfitting). Al forzar a la máquina a aprender y optimizar iterativamente sobre los mismos registros clonados y copiados en bucle, el modelo simplemente memoriza la topología de los fraudes históricos y pierde resiliencia predictiva frente a nuevas o evolutivas tipologías criminales futuras.[58]
SMOTE (Synthetic Minority Over-sampling Technique)	Creación algorítmica de datos transaccionales sintéticos completamente nuevos mediante la interpolación matemática de espacios multidimensionales entre muestras	Soluciona la debilidad fundamental del *oversampling* tradicional evitando el sobreajuste propio de la replicación exacta al inyectar variación matemática y diversidad en las	A pesar de su popularidad metodológica, exhibe un rendimiento computacional subóptimo y pérdida de coherencia geométrica en conjuntos de datos de altísima

	vecinas reales de la clase minoritaria, basándose fundamentalmente en el cálculo de distancias de los k-vecinos más cercanos (k-nearest neighbors o k-NN).[56]	características sintéticas generadas. Ha demostrado de forma contundente en experimentos empíricos superar a los métodos aleatorios simples, elevando dramáticamente métricas críticas como el Área Bajo la Curva ROC (AUC-ROC), el F1-Score y la precisión geométrica del límite de decisión de los clasificadores.[55]	dimensionalidad. Tiene la fuerte tendencia a generar ruido estadístico indeseado y potencialmente introducir "overfitting" al crear muestras sintéticas probabilísticas en zonas límite de denso solapamiento entre las clases, ignorando a menudo distribuciones locales de densidad específicas de los datos subyacentes.[62]

La aplicación rigurosa de algoritmos generativos de data sintética como **SMOTE**, combinada con preprocesamiento avanzado o algoritmos robustos de ensamble (a menudo referidos en la literatura como Hybrid SMOTE, SMOTE-NC o ensambles SMOTETomek), constituye en el estado del arte actual la práctica científica más equilibrada para mejorar el parámetro de "Recall" (sensibilidad predictiva) del evento fraudulento sin incurrir en la destrucción masiva de la arquitectura transaccional legítima. Sin embargo, su implementación en entornos de fraude reales exige protocolos exhaustivos de validación cruzada para mitigar la amplificación del ruido inducido en el pipeline de datos.[55]

Justificación Teórica de la Selección y Calibración de Modelos de Clasificación

Los requerimientos del diseño del sistema y la literatura en ciencia de datos demandan la evaluación empírica rigurosa y la justificación teórica profunda de tres aproximaciones modelísticas estructuralmente diversas. La evaluación comparativa de la pertinencia de estos algoritmos está extensamente soportada por experimentación controlada publicada sobre repositorios públicos y anonimizados de la industria financiera mundial (como los renombrados datasets *IEEE-CIS Fraud Detection* o repositorios europeos de fraude en tarjetas de crédito).[2]

1. Regresión Logística (Aprendizaje Sensible al Costo y Calibración Dinámica de Umbrales)

Aunque tradicionalmente es considerada en la academia como un algoritmo base de clasificación paramétrica y lineal simple, la Regresión Logística (LR) sigue ostentando la posición de estándar de oro para la interpretabilidad analítica en sectores fuertemente regulados como la banca corporativa y los seguros.[69] Mecánicamente, la regresión logística modela la relación entre las variables dependientes e independientes calculando la probabilidad posterior precisa de que un evento o transacción específica pertenezca a la clase fraudulenta, expresada estadísticamente como $P(Y = 1|X)$.[54] El aspecto vital y metodológicamente transformador de la aplicación de la LR en este contexto particular no reside en su complejidad arquitectónica (la cual es limitada comparada con el aprendizaje profundo), sino en la flexibilidad y manipulación matemática de su límite o umbral de decisión (Decision Threshold).

En un flujo de modelado predictivo de clasificación binaria tradicional, el algoritmo se configura con un umbral estático y predeterminado de 0.5.[72] No obstante, la investigación de frontera sobre el Aprendizaje Sensible al Costo (Cost-Sensitive Classification Data Mining) postula con firmeza que tratar a todos los errores de clasificación (falsos positivos frente a falsos negativos) con el mismo peso matemático es una aproximación inviable y destructiva financieramente en entornos reales.[49] Las implicaciones económicas dictan que fallar en detectar una inyección fraudulenta multimillonaria tiene un peso adverso específico infinitamente superior que el costo de contactar de manera automatizada a un cliente para verificar una compra legítima de bajo monto.[49]

En consecuencia, la literatura técnica sugiere imperativamente la alteración dinámica y la calibración exhaustiva de los umbrales de predicción probabilística de la regresión logística (por ejemplo, reduciendo agresivamente el threshold al valor de **0.2** para forzar un aumento exponencial en la sensibilidad de captura, o por el contrario, elevándolo a niveles conservadores de **0.78** para suprimir la fricción operativa en cohortes demográficas de historial comprobado y bajo riesgo transaccional). Esta calibración estocástica se basa en la aplicación algorítmica de matrices de costos reales y en los teoremas de minimización de riesgo bayesiano (Bayes Minimum Risk Classifier).[5] Esta variación metódica es la única herramienta matemática que permite al negocio optimizar empírica y financieramente el Indicador Clave de Rendimiento predefinido de la Ganancia Neta (

$$GN$$

), encontrando el punto óptimo en la curva de rendimiento que equilibre de forma perfecta el ahorro derivado de los fraudes detenidos frente a la escalada de los costos operativos de investigación administrativa.[5]

2. Random Forest (Estrategias de Ensamble Paralelo, Pesos Balanceados y Bootstrap)

El algoritmo de Bosques Aleatorios o Random Forest (RF) es una técnica sofisticada de ensamble de aprendizaje supervisado fundamentada en la filosofía de la "sabiduría de las multitudes" (wisdom of the crowd). Funciona mediante la construcción concurrente y la

agregación de los resultados predictivos de múltiples árboles de decisión profundos y estadísticamente descorrelacionados.[1] Su altísima idoneidad, popularidad y dominio en competiciones de ciencia de datos aplicadas a la detección de fraude se justifica científicamente a través del comportamiento de tres hiperparámetros cruciales y configurables, extensamente analizados en la literatura:

- **Aplicación de Bootstrap (Bootstrap = True / Bagging):** La arquitectura de agregación por remuestreo con reemplazo (Bootstrap Aggregating o Bagging) dicta que cada árbol individual que compone el bosque sea entrenado utilizando un subconjunto estadísticamente aleatorio e independiente de los datos de entrenamiento totales. Esta inyección de estocasticidad introduce una enorme diversidad en los patrones aprendidos y reduce drásticamente la varianza matemática global del modelo. Este mecanismo convierte al Random Forest en una herramienta inmensamente resistente frente al fenómeno de sobreajuste (overfitting), una característica indispensable al modelar datos financieros altamente ruidosos y volátiles.[5]
- **Gestión Heurística de Clases (class_weight = 'balanced'):** Frente a la disparidad extrema de las clases transaccionales descrita anteriormente, esta configuración algorítmica obliga a la función de pérdida y ganancia de información (Gini o Entropía) del árbol a asignar penalizaciones que son matemáticamente inversamente proporcionales a las frecuencias reales de las clases en la población.[5] Es decir, un error al clasificar erróneamente la minúscula clase minoritaria (fraude) es castigado por el compilador con una severidad matemática abrumadoramente mayor que un error en la inmensa clase mayoritaria. Este ajuste de pesos internos obliga a la red de nodos de decisión a enfocar sus divisiones y optimizar el espacio vectorial agresivamente en torno a los patrones del fraude.[6][7]
- **Volumen de Estimadores y Fractura de Características (n_estimators y max_features):** Escalar y elevar la magnitud de la cantidad de estimadores subyacentes (realizando ensayos iterativos incrementando la red de, por ejemplo, 100 a 500 árboles independientes) estabiliza profundamente la convergencia de la predicción final promediada. Simultáneamente, obligar al algoritmo a emplear raíces cuadradas para la selección aleatoria de un subconjunto de características en cada ramificación de nodo (max_features='sqrt') garantiza metodológicamente que ninguna variable fuertemente dominante (como el monto de la transacción) eclipse las señales predictivas débiles, tenues pero vitales de variables periféricas que denotan un comportamiento cibernético anómalo.[5] Diversos estudios empíricos referenciados y validados demuestran que la amalgama de técnicas Random Forest, cuando son finamente hiperparametrizadas y adaptadas a datos desbalanceados, logran de forma consistente e irrefutable métricas compuestas de F1-Scores superiores y curvas de operación (AUC-ROC) que exceden el 97% y el 99% de rendimiento.[1]

3. CatBoost (Categorical Gradient Boosting y Arquitectura Secuencial)

En la evolución contemporánea del modelado predictivo aplicado a datos tabulares

estructurados, CatBoost (Categorical Boosting), desarrollado por ingenieros de Yandex, se posiciona como el pináculo del rendimiento algorítmico.[3] Este modelo pertenece a la élite de la familia de algoritmos basados en árboles de decisión optimizados por potenciación del gradiente (Gradient Boosting Decision Trees - GBDT).[1] A diferencia diametral del paradigma de Random Forest, que entrena sus cientos de árboles en configuración paralela y de manera matemáticamente independiente, CatBoost los construye de forma estrictamente secuencial y aditiva. En este paradigma avanzado, cada nuevo árbol de la secuencia es entrenado específicamente para corregir iterativamente los gradientes de error residuales (loss function gradient residuals) generados en la iteración por el ensamble de los árboles que le precedieron.[80]

La densa literatura indexada en el dominio de ciberseguridad financiera y arquitecturas de data mining ensalza a CatBoost justificando su superioridad técnica por la integración de dos innovaciones algorítmicas de vanguardia absoluta que lo separan de sus competidores:

1. **Ingeniería y Manejo Nativo de Variables Categóricas (Target Encoding y Permutaciones):** La morfología del fraude financiero moderno no depende exclusivamente de valores numéricos absolutos, sino fundamentalmente de una vasta red de metadatos categóricos complejos y de altísima cardinalidad (como el tipo de dispositivo de red, el modelo del smartphone, la geolocalización, el dominio de correo electrónico estructurado o los identificadores anónimos del comercio).[2] Algoritmos legados fallan al procesar estos datos, exigiendo ineficientes conversiones a matrices dispersas (One-Hot Encoding). CatBoost procesa y absorbe estas variables categóricas internamente en su arquitectura central mediante sofisticadas permutaciones dinámicas y técnicas de codificación de respuesta ordenada (Ordered Target Encoding). Esta innovación elimina de raíz el riesgo sistémico y catastrófico de fuga de información y sesgo histórico (Target Leakage), maximizando el poder predictivo de los metadatos transaccionales sin destruir la memoria computacional.[2]
2. **Arquitectura de Árboles Simétricos (Oblivious Trees) y Estabilidad de Baja Latencia:** A nivel topológico, CatBoost genera árboles de decisión perfectamente balanceados y geométricamente simétricos (oblivious trees). Esta simetría estructural restringe la complejidad y reduce drásticamente los tiempos algorítmicos de inferencia y despliegue en entornos de producción en vivo (asegurando tiempos de latencia ínfimos, un requerimiento técnico insalvable en el procesamiento de tarjetas de crédito en tiempo real).[43] Múltiples investigaciones corporativas, académicas y análisis comparativos exhaustivos (benchmarks) determinan concluyentemente que, al someter los algoritmos a optimización y sintonización profunda de hiperparámetros (Hyperparameter Tuning), CatBoost supera de forma consistente y holgada a otros reconocidos modelos de la familia GBDT (como los omnipresentes XGBoost o LightGBM).[2] Se destaca por la robustez y estabilidad inquebrantable de su desempeño, su formidable capacidad de generalización sobre vectores de datos masivamente desbalanceados, obteniendo en laboratorios métricas de calibración probabilística como Brier Scores extremadamente bajos (e.g., 0.0004), métricas globales de AUC rozando la perfección en valores de

0.9837, métricas compuestas de F1-Score superiores al 86.36% (superando de forma aislada a los Random Forests estandarizados), y demostrando una precisión superior e inigualable en entornos de prueba paralelos y escenarios ruidosos simulados del mundo financiero real.[1]

Arquitectura Analizada y Modelo de Inteligencia Artificial	**Paradigma Algorítmico y Fundamento Matemático**	**Ventaja Científica Fundamental Demostrada y Justificada para la Detección Práctica de Fraude**
Regresión Logística (Cost-Sensitive LR)	Clasificación Lineal Probabilística P(Y|X)	Permite una transparencia matemática absoluta, facilidad de escrutinio regulatorio y una calibración dinámica, manual y fluida sensible a los costos para optimizar económicamente el KPI operativo de Ganancia Neta (GN) mediante la alteración estratégica e iterativa de los *thresholds* de probabilidad.[32]
Random Forest Classifier (RF)	Ensamble Paralelo y Promediado (Bootstrap Aggregating / Bagging)	Demuestra una resiliencia y robustez geométrica extrema ante el sobreajuste (mediante iteraciones controladas de Bootstrap) y provee una flexibilidad técnica nativa, rápida y eficaz para la penalización asimétrica de errores clasificatorios sobre las clases a través del ajuste del hiperparámetro interno *class_weight*.[67]
CatBoost (Categorical	Potenciación de Gradiente	Exhibe un manejo nativo,

Gradient Boosting)	Secuencial, Iterativo y Aditivo	superior e insuperable de metadatos categóricos de alta cardinalidad, inmunidad matemática total frente al fenómeno de fuga de datos espurios (Target Leakage), una capacidad de inferencia y despliegue de latencia ultrabaja a escala masiva, y métricas ROC-AUC consistentemente superiores a sus competidores inmediatos.[1]

Fase 4: Implicaciones Éticas de la IA en la Toma de Decisiones Financieras

El despliegue tecnológico en entornos de producción en vivo de arquitecturas algorítmicas de clasificación avanzadas como los ensambles de GBDT (CatBoost) o las inmensas redes de Random Forest evaluados en la sección previa, no constituye, bajo ninguna métrica, un mero y aséptico ejercicio de ingeniería de software corporativo. Por el contrario, representa sociológicamente una de las transferencias masivas de poder de agencia y autonomía más significativas en la historia corporativa reciente: el traslado de la facultad de toma de decisiones determinísticas desde el criterio, la sensibilidad y el juicio humano, hacia sistemas matemáticos, estocásticos y enteramente automatizados.

La copiosa literatura científica de actualidad, respaldada por lineamientos de observatorios internacionales como la OCDE y foros económicos globales, enfatiza categóricamente que la integración generalizada de plataformas de IA en los núcleos de los servicios financieros contemporáneos exige de manera irrenunciable el acatamiento riguroso de una nueva rama de estudio: la ética algorítmica y computacional.[85] Este campo incipiente pero crítico se encuentra estructurado metodológicamente a nivel mundial bajo los innegociables pilares y principios FAccT (Fairness, Accountability, and Transparency — Equidad, Rendición de Cuentas y Transparencia).[85]

El Impacto Disruptivo en los Derechos del Usuario Final y la Epidemia del Sesgo Algorítmico

La automatización programática de la decisión restrictiva de bloquear o permitir de forma autónoma una transferencia monetaria incide diametral, profunda y directamente en el núcleo esencial de los derechos fundamentales del ciudadano y consumidor financiero en Colombia.[11] En la doctrina prevalente y humanista de la Corte Constitucional colombiana, el acceso libre y sin discriminación a los servicios del sistema financiero no debe ser interpretado llanamente

como un privilegio comercial o de consumo marginal; es, en la era contemporánea, una condición estructural absolutamente indispensable para la correcta inserción en la dinámica económica formal y el desarrollo garantizado del libre proyecto de vida de la persona y la familia.[23]

La automatización masiva, cuando es operada de forma no supervisada o en ecosistemas de datos históricamente deficientes, introduce un vector de riesgo formidable e invisible en la operación bancaria: el fenómeno de la discriminación y el sesgo algorítmico (Algorithmic Bias). Múltiples investigaciones institucionales y estudios globales realizados en la compleja intersección de la provisión de finanzas digitales, la inclusión social y la ética del Machine Learning revelan, de forma preocupante, un patrón recurrente: los algoritmos matemáticos, a pesar de carecer de voluntad o prejuicios emocionales consientes, si son entrenados y alimentados con bases de datos históricas que contienen sesgos humanos o variables correlacionadas imperfectamente, tienden ineludiblemente a mimetizar, asimilar, perpetuar y codificar matemáticamente iniquidades y desigualdades sociodemográficas estructurales preexistentes en la sociedad civil.[86]

El proceso de entrenamiento no vigilado permite que la Inteligencia Artificial aprenda mecánicamente a asociar, mediante falsas inferencias estadísticas, altas tasas de riesgo financiero o comportamientos propensos al fraude cibernético con vectores demográficos específicos e inocentes. Estas correlaciones espurias terminan castigando de forma sistemática atributos poblacionales geográficos y sociales (por ejemplo, residentes de códigos postales históricamente excluidos o zonas geográficas marginadas de la capital), niveles de ingreso subrepresentados en la data general, o perfiles técnicos como el uso exclusivo de ciertos tipos de dispositivos móviles de gamas más económicas, afectando directamente a lo que la literatura anglosajona denomina clientes "Thin-file" (consumidores con historiales crediticios o de datos sumamente delgados, incipientes o atípicos).[91]

El resultado social y ético de esta negligencia en el diseño de los hiperparámetros es una violación flagrante y demostrable del principio angular de "Fairness" (Equidad), el cual combate directamente la discriminación sistémica documentada en las aplicaciones de la IA.[88] Bajo este pernicioso escenario algorítmico, perfiles poblacionales y sociodemográficos históricamente vulnerables e interseccionales, incidiendo con dolorosa desproporción estadística sobre las mujeres emprendedoras, poblaciones rurales, minorías étnicas y ciudadanos en procesos de reinserción económica, son sometidos a bloqueos preventivos de transacciones, denegación de pagos de servicios o suspensiones de crédito de manera injustificadamente alta y desproporcionada en comparación a grupos demográficos mayoritarios y favorecidos por la base de datos.[86]

En el estricto contexto constitucional colombiano del derecho al Hábeas Data, negar unilateralmente el acceso al libre comercio, retener fondos o bloquear pasarelas de pago basándose perezosamente en correlaciones matemáticas oscuras, extraídas de características accidentales y no causales, erosiona letalmente el principio constitucional de igualdad material ante la ley. Somete así a los usuarios indefensos a una tiranía de un régimen algorítmico

tecnocrático, donde la valiosa reputación ciudadana ("el derecho al buen nombre") es destruida o manchada de manera preventiva, no por acciones indebidas o delitos comprobados del usuario, sino por una fría y opaca inferencia estadística inferida por un conjunto de árboles de decisión inescrutables.[19]

Abordaje Crítico del Problema de la "Caja Negra" y la Demanda Legal de Explicabilidad

El obstáculo epistemológico, legal y operativo principal que agrava esta severa vulneración ética, y que las instituciones financieras luchan por resolver diariamente, se condensa en la literatura técnica bajo el concepto del problema de la "Caja Negra" (The Black-Box Problem of Artificial Intelligence).[47] Paradójicamente, la industria financiera se enfrenta a un dilema mefistofélico: los modelos predictivos estadísticamente más robustos, veloces y potentes, aquellos que fueron profunda y exitosamente justificados en las métricas de la Fase 3 del CRISP-DM por su capacidad excepcional de cazar fraudes complejos (especialmente los ensambles masivos de Random Forest y los sofisticados ecosistemas de potenciación de gradiente como CatBoost y XGBoost), logran invariablemente su extraordinaria precisión y sus deslumbrantes curvas de AUC superiores al 0.99 [1] precisamente a expensas de sacrificar de forma dramática la transparencia analítica y la opacidad matemática.[47]

La complejidad inherente al ensamble denso y anidado de miles de árboles de decisión interconectados de forma paralela o secuencial, cuyas ponderaciones se ajustan en espacios multidimensionales que escapan a la percepción tridimensional humana, imposibilita de facto que un analista de fraude humano, un supervisor financiero, un auditor externo o, mucho más preocupante aún, el propio ciudadano titular de los datos, comprenda de manera lógica y directa el enrevesado camino deductivo y probabilístico interno que derivó inequívocamente en la alerta, el bloqueo y la condena algorítmica de su transacción financiera legítima.[47]

Esta severa e infranqueable carencia o falta de transparencia destruye desde sus cimientos el segundo pilar innegociable de la metodología FAccT: el principio de "Accountability" o Rendición de Cuentas institucional, impidiendo exigir responsabilidades a los desarrolladores, operadores corporativos o entidades bancarias por los resultados y el daño colateral que las inferencias de sus redes producen en la vida de la ciudadanía.[86]

Aterrizando esta preocupación académica en el derecho nacional, la normativa colombiana de defensa irrestricta del consumidor financiero, fundamentada en directrices de la SFC y amparada por la Corte Constitucional, estipula que si la entidad mercantil bloquea una cuenta personal de ahorros, rechaza de tajo un pago vital o interrumpe un canal de transferencia (configurándose así un falso positivo con impacto material), el ciudadano afectado conserva de manera inalienable el derecho jurídico fundamental de conocer de manera clara, precisa y oportuna la razón, las fuentes y el *por qué* de esa decisión adversa que restringe su libertad económica.[21] Bajo el escrutinio de un juez de tutela o una inspección de la superintendencia, el banco no puede ni debe limitarse a responder evasivamente que "los algoritmos internos de alta complejidad, operados por proveedores tecnológicos de la computadora central, así lo

decidieron en fracciones de segundo basándose en lógicas propietarias inescrutables".

Para remediar eficazmente esta grosera asimetría de información y eludir quirúrgicamente los sesgos latentes codificados en los datos, la organización bancaria o entidad financiera que opte por el modelado de IA debe implementar simultánea, paralela e imperativamente ecosistemas avanzados y robustos de Inteligencia Artificial Explicable, conocidos globalmente por la sigla inglesa XAI (Explainable Artificial Intelligence). Estos ecosistemas operan superponiéndose o acoplándose metodológicamente sobre los outputs y resultados de las redes neuronales densas y de los ensambles complejos de árboles de decisión, traduciendo lo intraducible.[3]

El corpus de la literatura técnica y ética contemporánea es absolutamente unánime, contundente y resolutivo al sugerir, exigir y comprobar las bondades de la adopción integral de métodos matemáticos de interpretación avanzados que posean la característica fundamental de ser "agnósticos al modelo" (model-agnostic explanation methods), lo que significa que pueden diseccionar las razones de las decisiones sin importar si el motor subyacente es un ensamble XGBoost, una regresión o una red neuronal oculta. Entre estos métodos se destacan protagónica y universalmente dos herramientas indispensables de justificación:

- **SHAP (SHapley Additive exPlanations):** Constituye una aproximación algorítmica revolucionaria proveniente directamente del ámbito matemático de la teoría de juegos cooperativa clásica (basada en el trabajo del premio Nobel Lloyd Shapley). Este método asigna con absoluta rigurosidad matemática y de forma aditiva un "valor de contribución" estadísticamente exacto, positivo o negativo, a cada una de las variables categóricas, vectores numéricos y características transaccionales utilizadas por el modelo. SHAP permite al auditor, desglosando el peso interno del clasificador CatBoost o Random Forest, indicar y demostrar numéricamente, característica por característica, exactamente cuánto, cómo y en qué proporción contribuyó cada factor individual (por ejemplo, la coincidencia de IPs, la velocidad de escritura del usuario, o el monto atípico) al veredicto de rechazar la transacción en disputa.[47] Esta visibilidad cristalina disuelve la caja negra permitiendo una revisión humana objetiva, detallada y exhaustiva, libre de misterios algorítmicos.
- **LIME (Local Interpretable Model-Agnostic Explanations):** Complementando de forma dinámica y veloz al método SHAP, el framework LIME permite, mediante perturbaciones sistémicas en los datos de entrada, aproximar y simular el comportamiento complejo local de la indescifrable "caja negra" operando estrictamente en las micro-vecindades matemáticas de una predicción específica e individual.[47] Este método resulta extraordinariamente valioso para los departamentos legales y de servicio al cliente de las entidades financieras, pues posee la encomiable virtud de traducir y destilar el complejo e inescrutable dictamen probabilístico multidimensional emitido por la máquina de vectores o el ensamble de miles de árboles iterativos, reconvirtiéndolo rápida y dinámicamente en un formato explicativo lineal, simplificado y humanamente comprensible.[47] Esta traducción lingüística y visual de la matemática subyacente permite a los analistas humanos justificar operativa y transparentemente ante el cliente final y ante las autoridades la veracidad y

validez probatoria de la alerta de ciberseguridad gatillada.

Al emplear enfoques de arquitectura de software híbridos y metodologías de diseño verdaderamente vanguardistas y holísticas que combinan el indudable poder predictivo bruto de modelos de frontera GBDT altamente hiperparametrizados, tales como CatBoost y Random Forest, con el poder exegético y de escrutinio de protocolos avanzados de evaluación ética XAI como las estructuras SHAP y LIME, la entidad financiera logra una sinergia inusitada. Concilia definitivamente, y por primera vez en el desarrollo del proyecto CRISP-DM, el máximo rigor empírico y científico de predicción econométrica que exige el salvaguardo de sus vastos activos institucionales, con el inquebrantable respeto y cumplimiento irrestricto de la ética institucional, la moralidad pública y la defensa estricta de los derechos de la ciudadanía.[47]

A través de esta integración metodológica, exhaustiva y transdisciplinaria —que abarca transversalmente desde la ciencia de datos profunda y la depuración del desbalance de clases estadísticas, pasando por la economía del comportamiento bancario, hasta llegar a la ponderación constitucional jurídica del debido proceso en la respuesta al cliente—, se satisface de forma absoluta y garantista el mandato legal imperativo de la auditoría humana sobre las máquinas, y se previenen cuantiosas multas institucionales. Simétricamente, se preservan de manera inviolable los supremos y sacrosantos principios constitucionales de la intimidad, la equidad, el Hábeas Data y la igualdad de trato frente a las herramientas corporativas modernas. En síntesis y conclusión, la organización abandona las prácticas riesgosas, reactivas y discriminatorias del pasado estático para instaurar de forma efectiva un modelo tecnológico de protección patrimonial y de servicios financieros que se caracteriza innegablemente por ser transparente, tecnológicamente invulnerable, socialmente justo, explicable al detalle, y, sobre todo, responsable y humanamente invocable ante las leyes vigentes de la República de Colombia.[85]

Obras citadas

1. Enhancing credit card fraud detection with a stacking-based hybrid machine learning approach - PMC, fecha de acceso: abril 9, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12453863/
2. Evaluating Performance of Machine Learning Methods for Credit Card Fraud Detection Using CatBoost - IJSDR, fecha de acceso: abril 9, 2026, https://ijsdr.org/papers/IJSDR2401084.pdf
3. CatBoost for Fraud Detection in Financial Transactions - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/349156860_CatBoost_for_Fraud_Detection_in_Financial_Transactions
4. 3 Trends Shaping the Consumer Payments Landscape - Euromonitor International, fecha de acceso: abril 9, 2026, https://www.euromonitor.com/article/3-trends-shaping-the-consumer-payments-landscape
5. Taller_deteccion_fraude.pdf

6. Leyes desde 1992 - Vigencia expresa y control de constitucionalidad [LEY_0599_2000_PR012] - Secretaria del Senado, fecha de acceso: abril 9, 2026, http://www.secretariasenado.gov.co/senado/basedoc/ley_0599_2000_pr012.html
7. Ley 599 de 2000 Congreso de la República de Colombia, fecha de acceso: abril 9, 2026, https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=6388
8. LEY 599 DE 2000 - OAS.org, fecha de acceso: abril 9, 2026, https://www.oas.org/dil/esp/codigo_penal_colombia.pdf
9. LEY 599 DE 2000 - SUIN-Juriscol, fecha de acceso: abril 9, 2026, https://www.suin-juriscol.gov.co/viewDocument.asp?id=1663230
10. Ley 599 de 2000 - Gestor Normativo - Función Pública, fecha de acceso: abril 9, 2026, https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=6388
11. PARTIDO POLÍTICO INTEGRIDAD DEMOCRÁTICA PLAN DE GOBIERNO 2026 - 2031 - LP, fecha de acceso: abril 9, 2026, https://img.lpderecho.pe/wp-content/uploads/2025/12/Partido-Integridad-Democratica-Plan-de-Gobierno-LP.pdf
12. Colombia's Capacity to Recover Criminal Assets: An Assessment Based on the 9 Principles of Asset Recovery - Basel Institute on Governance, fecha de acceso: abril 9, 2026, https://baselgovernance.org/sites/default/files/2022-07/220725_Diagna%CC%A8stico_Colombia_report_En.pdf
13. RESPONSABILIDAD BANCARIA CONTRACTUAL–Derivada de la falta de consentimiento del cuentacorrentista en la asignación, por parte - Corte Suprema de Justicia, fecha de acceso: abril 9, 2026, https://cortesuprema.gov.co/corte/wp-content/uploads/2016/12/SC16496.pdf
14. Leyes desde 1992 - Vigencia expresa y control de constitucionalidad [CODIGO_CIVIL_PR072] - Secretaria del Senado, fecha de acceso: abril 9, 2026, http://www.secretariasenado.gov.co/senado/basedoc/codigo_civil_pr072.html
15. ¿Qué hacer si quiero solicitar una indemnización porque una persona con la que teníamos un negocio realizó una conducta no permitida pero no cuento con el contrato? - Ministerio de Justicia y del Derecho, fecha de acceso: abril 9, 2026, https://www.minjusticia.gov.co/programas-co/LegalApp/Paginas/responsabilidad-civil.aspx
16. SC 18614-2016 - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1022513
17. BLOQUEO DE PRODUCTOS, DEBIDA DILIGENCIA Concepto 2024012094-001 del 19 de febrero de 2024 Síntesis: Las entidades vigiladas, en - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1070380
18. ENTIDADES VIGILADAS, RESPONSABILIDAD POR FRAUDE EN ..., fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/publicaciones/10108403/normativanormativa-generalboletin-juridico-superintendencia-financieraboletin-juridico-numero-entidade

s-vigiladas-responsabilidad-por-fraude-en-la-realizacion-de-operaciones-10108403/
19. CONSTITUCIÓN POLÍTICA DE COLOMBIA 1991 ARTÍCULO 15— Todas las personas tienen derecho a su intimidad personal y familiar y, fecha de acceso: abril 9, 2026, https://www.mincit.gov.co/ministerio/normograma-sig/procesos-estrategicos/gestion-de-informacion-y-comunicacion/constitucion-politica/derechos/articulo-15.aspx
20. Hábeas Data - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/publicaciones/15371/habeas-data-15371/
21. SENTENCIA T-584 de 2023 - SUIN-Juriscol, fecha de acceso: abril 9, 2026, https://www.suin-juriscol.gov.co/viewDocument.asp?id=30051307
22. Sentencia T-255/22 - Corte Constitucional, fecha de acceso: abril 9, 2026, https://www.corteconstitucional.gov.co/relatoria/2022/t-255-22.htm
23. Corte Constitucional de Colombia frena exclusión bancaria a exconvictos, fecha de acceso: abril 9, 2026, https://www.diarioconstitucional.cl/2025/06/23/corte-constitucional-de-colombia-frena-exclusion-bancaria-a-exconvictos/
24. T-479/23 Corte Constitucional de Colombia, fecha de acceso: abril 9, 2026, https://www.corteconstitucional.gov.co/relatoria/2023/t-479-23
25. T-716/17 Corte Constitucional de Colombia, fecha de acceso: abril 9, 2026, https://www.corteconstitucional.gov.co/relatoria/2017/t-716-17
26. Ley 1266 de 2008 - Gestor Normativo - Función Pública, fecha de acceso: abril 9, 2026, https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=34488
27. Sentencia T-113 de 2025 - Corte Constitucional, fecha de acceso: abril 9, 2026, https://www.corteconstitucional.gov.co/relatoria/2025/t-113-25.htm
28. REPUBLICA DE COLOMBIA RAMA JUDICIAL DEL PODER PUBLICO JUZGADO TERCERO PENAL DEL CIRCUITO CON FUNCIONES MIXTAS Bucaramanga, d - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1047407
29. CONCEPTO 2024012094-001 DEL 19 DE FEBRERO DE 2024 (19/02/2024) SUPERINTENDENCIA FINANCIERA DE COLOMBIA - OCH Group, fecha de acceso: abril 9, 2026, https://www.ochgroup.co/norma/concepto-2024012094-001-del-19-de-febrero-de-2024-19-02-2024-superintendencia-financiera-de-colombia/
30. Circular Externa 004 de 2024 - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1069605
31. [2005.02488] Instance-Dependent Cost-Sensitive Learning for Detecting Transfer Fraud, fecha de acceso: abril 9, 2026, https://arxiv.org/abs/2005.02488
32. A High-Recall Cost-Sensitive Machine Learning Framework for Real-Time Online Banking Transaction Fraud Detection - arXiv, fecha de acceso: abril 9, 2026, https://arxiv.org/html/2601.07276v2
33. FBME Bank Ltd. et al. v. Jacob Lew - Crowell & Moring LLP, fecha de acceso: abril

9, 2026, https://www.crowell.com/a/web/6pyK2JtNL3VxhdbonJZdRm/4TtivV/20160920-FBME-Bank-v-Lew.pdf
34. Número de Radicación : 2024053654-014-000 Trámite : 506 FUNCIONES JURISDICCIONALES Actividad - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1075441.pdf
35. Revista N 2 -IPDRC Noviembre 2024 - Instituto Peruano de Responsabilidad Civil, fecha de acceso: abril 9, 2026, https://ipdrcperu.com/wp-content/uploads/2025/01/Revista-N-2-IPDRC-Noviembre-2024.pdf
36. LA PROCEDENCIA DE LA ACCIÓN DE TUTELA CONTRA ENTIDADES FINANCIERAS Y/O BANCARIAS - SciELO Colombia, fecha de acceso: abril 9, 2026, http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S1909-44502023000100225
37. SFC - Informe de Gestión 2024 - Superintendencia Financiera, fecha de acceso: abril 9, 2026, https://www.superfinanciera.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=1073758
38. Financial Cards and Payments - Explore reports - Euromonitor.com, fecha de acceso: abril 9, 2026, https://www.euromonitor.com/store/explore-reports/payments-and-lending/financial-cards-and-payments
39. A Proposed Model for Card Fraud Detection Based on CatBoost and Deep Neural Network - IEEE Xplore, fecha de acceso: abril 9, 2026, https://ieeexplore.ieee.org/iel7/6287639/6514899/09882043.pdf
40. A Proposed Model for Card Fraud Detection Based on CatBoost and Deep Neural Network - SciSpace, fecha de acceso: abril 9, 2026, https://scispace.com/pdf/a-proposed-model-for-card-fraud-detection-based-on-catboost-1nyz7f3m.pdf
41. Financial Cards and Payments in Latin America | Market Research Report | Euromonitor, fecha de acceso: abril 9, 2026, https://www.euromonitor.com/financial-cards-and-payments-in-latin-america/report
42. Page 1 of 3 - Euromonitor International, fecha de acceso: abril 9, 2026, https://www.euromonitor.com/abstractreport/downloadtocasync?currentContentId=626977
43. (PDF) Comparative Study of Efficient Machine Learning Models for Real-Time Fraud Detection: CatBoost, XGBoost and LightGBM - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/395370886_Comparative_Study_of_Efficient_Machine_Learning_Models_for_Real-Time_Fraud_Detection_CatBoost_XGBoost_and_LightGBM
44. Application of Machine Learning Model in Fraud Identification: A Comparative

Study of CatBoost, XGBoost and LightGBM - Preprints.org, fecha de acceso: abril 9, 2026, https://www.preprints.org/manuscript/202503.1199
45. The State of Fraud and Financial Crime in the U.S. | Featurespace, fecha de acceso: abril 9, 2026, https://www.featurespace.com/the-state-of-fincrime-in-the-us-2022-report
46. Fraud Costs and Volumes Remain Significantly Higher than Pre-Pandemic for Financial Services and Lending Firms, According to New LexisNexis Risk Solutions Report, fecha de acceso: abril 9, 2026, https://risk.lexisnexis.com/about-us/press-room/press-release/20220106-annual-true-cost-of-fraud-study
47. Financial Fraud Detection Using Explainable AI and Stacking Ensemble Methods - arXiv, fecha de acceso: abril 9, 2026, https://arxiv.org/html/2505.10050v1
48. Financial Fraud Detection Using Explainable AI and Stacking Ensemble Methods - arXiv, fecha de acceso: abril 9, 2026, https://arxiv.org/pdf/2505.10050
49. 2. Cost-sensitive learning — Reproducible Machine Learning for Credit Card Fraud detection - Practical handbook, fecha de acceso: abril 9, 2026, https://fraud-detection-handbook.github.io/fraud-detection-handbook/Chapter_6_ImbalancedLearning/CostSensitive.html
50. Fraud detection with cost-sensitive machine learning | by Roman Moser - Medium, fecha de acceso: abril 9, 2026, https://medium.com/data-science/fraud-detection-with-cost-sensitive-machine-learning-24b8760d35d9
51. Friction From Fraud-Fighting Weighs Heavily on Consumers - PaymentsJournal, fecha de acceso: abril 9, 2026, https://www.paymentsjournal.com/friction-from-fraud-fighting-weighs-heavily-on-consumers/
52. Example-Dependent Cost-Sensitive Classification - ORBilu, fecha de acceso: abril 9, 2026, https://orbilu.uni.lu/bitstream/10993/22367/1/Thesis_ExampleDependentCostSensitiveClassification.pdf
53. Minimizing fraud losses using cost-sensitive machine learning and learning to rank - Leuven.AI, fecha de acceso: abril 9, 2026, https://ai.kuleuven.be/stories/post/2022-06-07-minimizing-fraud-losses/
54. Analyzing Best Models for Credit Card Fraud Detection - AIP Publishing, fecha de acceso: abril 9, 2026, https://pubs.aip.org/aip/acp/article-pdf/doi/10.1063/5.0218660/20082110/020272_1_5.0218660.pdf
55. Comparative Analysis of Undersampling, Oversampling, and SMOTE Techniques for Addressing Class Imbalance in Phishing Website Detection - The Science and Information (SAI) Organization, fecha de acceso: abril 9, 2026, https://thesai.org/Downloads/Volume16No2/Paper_76-Comparative_Analysis_of_Undersampling_Oversampling.pdf
56. Enhancing Financial Fraud Detection through Addressing Class Imbalance Using Hybrid SMOTE-GAN Techniques - MDPI, fecha de acceso: abril 9, 2026, https://www.mdpi.com/2227-7072/11/3/110

57. An Examination of the Smote and Other Smote-based Techniques That Use Synthetic Data to Oversample the Minority Class in the - CORE, fecha de acceso: abril 9, 2026, https://core.ac.uk/download/pdf/301313492.pdf
58. Oversampling Techniques in Machine Learning Detection of Credit Card Fraud | Infonomics Society, fecha de acceso: abril 9, 2026, https://infonomics-society.org/wp-content/uploads/Oversampling-Techniques-in-Machine-Learning-Detection-of-Credit-Card-Fraud.pdf
59. Fraud Detection Using Random Forest Classifier, Logistic Regression, and Gradient Boosting Classifier Algorithms on Credit Cards - Neliti, fecha de acceso: abril 9, 2026, https://media.neliti.com/media/publications/442461-fraud-detection-using-random-forest-clas-f5349636.pdf
60. A comprehensive evaluation of oversampling techniques for enhancing text classification performance - PMC, fecha de acceso: abril 9, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12217700/
61. Class balancing framework for credit card fraud detection based on clustering and similarity-based selection (SBS) - PMC, fecha de acceso: abril 9, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC9209320/
62. A Comparison of Undersampling, Oversampling, and SMOTE Methods for Dealing with Imbalanced Classification in Educational Data Mining - MDPI, fecha de acceso: abril 9, 2026, https://www.mdpi.com/2078-2489/14/1/54
63. Cost-Sensitive Learning for Medical Insurance Fraud Detection With Temporal Information - Simon Fraser University, fecha de acceso: abril 9, 2026, https://www.sfu.ca/science/stat/cao/Papers/Fraud.pdf
64. (PDF) Comparative Analysis of Undersampling, Oversampling, and SMOTE Techniques for Addressing Class Imbalance in Phishing Website Detection - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/389465390_Comparative_Analysis_of_Undersampling_Oversampling_and_SMOTE_Techniques_for_Addressing_Class_Imbalance_in_Phishing_Website_Detection
65. Imbalanced Data Problem in Machine Learning: A Review - IEEE Xplore, fecha de acceso: abril 9, 2026, https://ieeexplore.ieee.org/iel8/6287639/10820123/10845793.pdf
66. Comparison Analysis: Logistic Regression, Random Forest, XGBoost, and CatBoost in Credit Scoring - Atlantis Press, fecha de acceso: abril 9, 2026, https://www.atlantis-press.com/article/126017784.pdf
67. Credit Card Fraud Detection Using Enhanced Random Forest Classifier for Imbalanced - arXiv, fecha de acceso: abril 9, 2026, https://arxiv.org/pdf/2303.06514
68. IEEE-CIS Fraud Detection with Random Forest - Kaggle, fecha de acceso: abril 9, 2026, https://www.kaggle.com/code/toobarahimnia/ieee-cis-fraud-detection-with-random-forest
69. Big Data-Driven Distributed Machine Learning for Scalable Credit Card Fraud Detection Using PySpark, XGBoost, and CatBoost - MDPI, fecha de acceso: abril

9, 2026, https://www.mdpi.com/2079-9292/14/9/1754
70. An Introduction to Machine Learning Methods for Fraud Detection - MDPI, fecha de acceso: abril 9, 2026, https://www.mdpi.com/2076-3417/15/21/11787
71. (PDF) A Machine Learning Approach to Audit Modification Risk Prediction in Financial Reporting: Methods, Data, and Human-Centered Challenges - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/402527094_A_Machine_Learning_Approach_to_Audit_Modification_Risk_Prediction_in_Financial_Reporting_Methods_Data_and_Human-Centered_Challenges
72. Post-tuning the decision threshold for cost-sensitive learning - Scikit-learn, fecha de acceso: abril 9, 2026, https://scikit-learn.org/stable/auto_examples/model_selection/plot_cost_sensitive_learning.html
73. Cost Sensitive Credit Card Fraud Detection Using Bayes Minimum Risk - albahnsen, fecha de acceso: abril 9, 2026, https://albahnsen.github.io/files/Cost%20Sensitive%20Credit%20Card%20Fraud%20Detection%20using%20Bayes%20Minimum%20Risk%20-%20Publish.pdf
74. Cost-sensitive thresholding over a two-dimensional decision region for fraud detection - UDC, fecha de acceso: abril 9, 2026, http://dm.udc.es/preprint/Cost_sensitive_thresholding_for_fraud_detection.pdf
75. Comparing Regular Random Forest Model with Weighted Random Forest Model for Classification Problem - Scientific & Academic Publishing, fecha de acceso: abril 9, 2026, http://article.sapub.org/10.5923.j.statistics.20241401.02.html
76. Credit Card Fraud Detection Using Bootstrap Aggregation and Random Forest, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/392980232_Credit_Card_Fraud_Detection_Using_Bootstrap_Aggregation_and_Random_Forest
77. machine learning - Random Forest classifier class_weight - Stack Overflow, fecha de acceso: abril 9, 2026, https://stackoverflow.com/questions/47677754/random-forest-classifier-class-weight
78. Credit Card Fraud Detection Using Enhanced Random Forest Classifier for Imbalanced Data - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/369199151_Credit_Card_Fraud_Detection_Using_Enhanced_Random_Forest_Classifier_for_Imbalanced_Data
79. A Comparative Analysis of Credit Card Fraud Detection Machine Learning Algorithms, fecha de acceso: abril 9, 2026, https://ieeexplore.ieee.org/document/10533119/
80. (PDF) An Effective Classification of DDoS Attacks in a Distributed Network by Adopting Hierarchical Machine Learning and Hyperparameters Optimization Techniques - ResearchGate, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/377322481_An_Effective_Classification_of_DDoS_Attacks_in_a_Distributed_Network_by_Adopting_Hierarchical_Machine_Learning_and_Hyperparameters_Optimization_Techniques
81. An Effective Classification of DDoS Attacks in a Distributed Network by Adopting

Hierarchical Machine Learning and Hyperparamete - IEEE Xplore, fecha de acceso: abril 9, 2026, https://ieeexplore.ieee.org/iel7/6287639/10380310/10387439.pdf
82. An Effective Classification of DDoS Attacks in a Distributed Network by Adopting Hierarchical Machine Learning and Hyperparamete - IEEE Xplore, fecha de acceso: abril 9, 2026, https://ieeexplore.ieee.org/iel7/6287639/6514899/10387439.pdf
83. fraud detection in banking data by hybrid machine learning techniques - Jetir.Org, fecha de acceso: abril 9, 2026, https://www.jetir.org/papers/JETIR2504A09.pdf
84. Enhancing Fraud Detection in Banking using Advanced Machine Learning Techniques - EconJournals.com, fecha de acceso: abril 9, 2026, https://econjournals.com/index.php/ijefi/article/download/16613/8109/38708
85. Adoption of Artificial Intelligence-Driven Fraud Detection in Banking: The Role of Trust, Transparency, and Fairness Perception in Financial Institutions in the United Arab Emirates and Qatar - MDPI, fecha de acceso: abril 9, 2026, https://www.mdpi.com/1911-8074/18/4/217
86. Ethical Implications of AI in Financial Services: Bias, Transparency, and Accountability, fecha de acceso: abril 9, 2026, https://www.researchgate.net/publication/384713108_Ethical_Implications_of_AI_in_Financial_Services_Bias_Transparency_and_Accountability
87. COLOMBIA | Cetys, fecha de acceso: abril 9, 2026, https://cetys.lat/wp-content/uploads/2021/09/colombia-ENG.pdf
88. Full article: AI Ethics: Integrating Transparency, Fairness, and Privacy in AI Development, fecha de acceso: abril 9, 2026, https://www.tandfonline.com/doi/full/10.1080/08839514.2025.2463722
89. Toward Fairness, Accountability, Transparency, and Ethics in AI for Social Media and Health Care: Scoping Review - PMC, fecha de acceso: abril 9, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC11024755/
90. Algorithmic bias and financial services - Finastra, fecha de acceso: abril 9, 2026, https://www.finastra.com/sites/default/files/documents/2021/03/market-insight_algorithmic-bias-financial-services.pdf
91. Algorithmic Bias, Financial Inclusion, and Gender - Women's World Banking, fecha de acceso: abril 9, 2026, https://www.womensworldbanking.org/wp-content/uploads/2024/03/Algorithmic_Bias_Primer.pdf
92. Research Note: A Literature Review on Bias in Supervised Machine Learning - FCA, fecha de acceso: abril 9, 2026, https://www.fca.org.uk/publication/research-notes/literature-review-bias-in-supervised-machine-learning.pdf
93. Artificial Intelligence, Machine Learning, and Bias in Finance: Toward Responsible Innovation - The Fordham Law Archive of Scholarship and History, fecha de acceso: abril 9, 2026, https://ir.lawnet.fordham.edu/cgi/viewcontent.cgi?article=5629&context=flr
94. Women's Inclusion for Impact and Scale - Practical Design Guidance for Instant Payment Systems - The Level One Project, fecha de acceso: abril 9, 2026,

https://www.l1p.org/wp-content/uploads/2025/09/L1P-Formatted-FINAL-Womens-Inclusion-Whitepaper-Sept-29-.pdf
95. IA Y SESGOS: UNA VISIÓN ALTERNATIVA EXPRESADA DESDE LA ÉTICA Y EL DERECHO - Dialnet, fecha de acceso: abril 9, 2026, https://dialnet.unirioja.es/descarga/articulo/9870496.pdf
96. Privacy, ethics, transparency, and accountability in AI systems for wearable devices, fecha de acceso: abril 9, 2026, https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2025.1431246/full
97. Detecting Fraud Insurance Claims Using Machine Learning - NHSJS, fecha de acceso: abril 9, 2026, https://nhsjs.com/2025/detecting-fraud-insurance-claims-using-machine-learning/
98. ¿Prejuicios en la IA? Análisis del sesgo algorítmico y una propuesta de solución - SciELO México, fecha de acceso: abril 9, 2026, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S2594-21662025000401293